Mineração de Dados e Resolução de Entidades Espaciais no Cruzamento de Catálogos Astronômicos

Heloísa de Souza Ortiz e Vitória Gabriela Mohr de Lima
Sob orientação de: Prof(a). Rosanete Grassiani dos Santos

RESUMO

O presente artigo de iniciação científica evidencia a pesquisa aplicada de técnicas de mineração de dados por meio do cruzamento de catálogos astronômicos Chandra Source Catalog (CSC 2.0) e Sloan Digital Sky Survey (SDSS DR15), que contém 35.771 pares de fontes. O propósito central da pesquisa foi investigar a prática de métodos contingentes e de regras de associação para redução de imprecisões posicionais e identificar padrões entre a qualidade do match e a classificação estrutural dos objetos. Como metodologia, houveram cinco etapas: aquisição e armazenamento de dados em PostgreSQL; exploração e limpeza com discretização das variáveis de separação angular e probabilidade de match; identificação de inconsistências (3.385 pares, 10,54% dos classificados como "D" apresentaram simultaneamente probabilidade baixa e separação >2"); aplicação do algoritmo Apriori (suporte mínimo 1%, confiança mínima 60%) sobre a base limpa (32.386 pares); e validação dos resultados. Foram identificados 213 itemsets constantes e 449 regras de associação. A regra de máxima importância astrofísica (lift 1,33; confiança 65,4%) associou pares com match_grade=L, match_type=R e separação >2" à classificação morfológica de galáxia (G), confirmando que fontes extensas apresentam maior incerteza posicional. Como resultado, valida-se a hipótese de que métodos puramente baseados em distância fixa são limitados e que abordagens probabilísticas são mais adequadas para o cross-matching em panoramas de incerteza.

Palavras chave: *Mineração de Dados; Catálogos Astronômicos; SDSS DR15; CSC 2.0; Regras de Associação; Associação Cruzada.*

ABSTRACT

This undergraduate research article presents applied research on data mining techniques through the cross-matching of the astronomical catalogs Chandra Source Catalog (CSC 2.0) and Sloan Digital Sky Survey (SDSS DR15), which contains 35,771 source pairs. The central purpose of the research was to investigate the use of contingency methods and association rules to reduce positional inaccuracies and to identify patterns between match quality and the structural classification of objects. The methodology consisted of five stages: data acquisition and storage in PostgreSQL; exploration and cleaning with discretization of the angular separation and match probability variables; identification of inconsistencies (3,385 pairs, 10.54% of those classified as "D," simultaneously showed low probability and separation >2"); application of the Apriori algorithm (minimum support 1%, minimum confidence 60%) to the cleaned database (32,386 pairs); and validation of the results. A total of 213 frequent itemsets and 449 association rules were identified. The rule of greatest astrophysical importance (lift 1.33; confidence 65.4%) associated pairs with match_grade=L, match_type=R, and separation >2" with the morphological classification of galaxy (G), confirming that extended sources present greater positional uncertainty. As a result, the hypothesis is validated that methods based purely on fixed distance are limited and that probabilistic approaches are more suitable for cross-matching in surveys with uncertainty.

Keywords: *Data Mining; Astronomical Catalogs; SDSS DR15; CSC 2.0; Association Rules; Cross-Matching.*

1. INTRODUÇÃO

Na astronomia moderna, telescópios coletam diariamente terabytes de dados de objetos celestes, sejam eles: estrelas, planetas, cometas ou buracos negros. Inúmeros telescópios operam de áreas distintas no planeta e com diferentes especialidades: o Chandra observa em raios-X, o SDSS em luz visível e o JWST em infravermelho. Essas discrepâncias



geram dados distintos de um mesmo objeto devido à resolução e à forma de captação da luz. A razão crucial é o comprimento de onda: o JWST capta ondas longas galáxias antigas, centros galácticos, berçários estelares, exoplanetas); o SDSS decompõe a luz profundamente (galáxias distantes, quasares, composições estelares). Para compreensão destes objetos, se faz necessário o cruzamento de informações, chamado de Cross-Matching (associação cruzada).

A associação cruzada une dois catálogos distintos, somando dados de uma mesma região do céu (como por exemplo, o catálogo Chandra com fontes em raio-X e o SDSS em luz visível). A dificuldade prática é que as coordenadas de um mesmo astro raramente são iguais em catálogos distintos, devido a erros de astrometria e ruídos instrumentais (EVANS et al., 2010). Budavári e Szalay (2008) propuseram um método Bayesiano que calcula a probabilidade de duas fontes serem o mesmo objeto, considerando distância angular, elipses de erro e densidade local de fontes. Obtém-se uma probabilidade (0 a 1) e uma separação angular para cada par. Essa metodologia, aplicada ao cruzamento Chandra–SDSS (ROTS, 2020), gera dados de alta confiabilidade utilizados para mineração de conhecimento neste projeto.

O presente projeto de Iniciação Científica opera com fontes de raios-X do Chandra Source Catalog (CSC 2.0) e contrapartes ópticas do SDSS DR15, agrupados em um catálogo com 35.771 pares, incluindo probabilidades e classificações morfológicas. Como o cruzamento inicial já havia sido feito, o escopo da pesquisa focou para aplicação de técnicas de mineração de dados a partir desta base consumada, especificamente a extração de regras de associação (FREIRE, 2016), transformando dados somados em entendimento astrofísico explícito.

1.1 PROBLEMA

A partir da classificação de astros, pesquisas científicas revelaram diferenças nas informações obtidas por instrumentos distintos. Devido a erros de coleta, como objetos muito próximos, ruídos visuais, erros de astrometria e baixa resolução espacial, decorrem as variações, que comprometem a precisão e confiabilidade, além de causar deslocamentos de centróide e ambiguidades posicionais (HOGG, 2001). Essas diferenças tornam mais difícil a associação exata entre astros de catálogos diferentes, processo conhecido como Cross-Matching (associação cruzada) ou resolução de entidades espaciais (FREIRE,2016).

A partir do grande crescimento exponencial dos dados (Big Data na astronomia), determinadas regiões de densidade estelar trazem limitações para os métodos padrão baseados em distâncias fixas (FREIRE; PORTO; DE MACÊDO, 2017). Tais abordagens se mostram insuficientes e computacionalmente ineficientes para lidar com imprecisões em larga escala (FREIRE; PORTO; DE MACÊDO, 2017).



Pergunta de pesquisa: A partir do erro de confusão astrométrica e imprecisões posicionais comprometedoras na exatidão de resultados, que maneiras técnicas de análise, pesquisa e mineração de dados podem ser utilizadas na associação de objetos presentes em copiosos catálogos astronômicos?

1.2 JUSTIFICATIVA

Há comprometimento na exatidão e confiabilidade da associação cruzada entre catálogos trazendo diferenças nos dados registrados por telescópios distintos, devido a erros de resolução espacial, proximidade de objetos e confusão astrométrica (HOGG, 2001). Falsos positivos e falsos negativos são gerados por conta de limitações nos métodos baseados em distâncias fixas nas regiões de alta densidade estelar (FREIRE; PORTO; DE MACÊDO, 2017).

Esta pesquisa se justifica por meio de sua praticidade benéfica: o catálogo cruzado Chandra-SDSS contém 35.771 pares de fontes com probabilidades de associação, mas ainda não havia sido explorado com técnicas de mineração de regras; a aplicação de matching probabilístico e regras de associação pode reduzir ambiguidades posicionais, aumentando a confiabilidade dos resultados; e o procedimento proposto é replicável para outros levantamentos (LSST, Euclid), favorecendo a astronomia no tratamento de grandes volumes de dados.

1.3 OBJETIVOS

Objetivo geral: Para redução de incertezas na associação cruzada de fontes, aplicar e desenvolver estratégias computacionais de mineração de dados para a associação cruzada entre os catálogos CSC 2.0 e SDSS DR15.

Objetivos específicos:

- Identificar variáveis responsáveis pelas inconsistências registradas a partir da análise de diferença nos dados obtidos por instrumentos distintos.
- Investigar fatores físicos e instrumentais, como erros de confusão astrométrica que afetam a precisão das informações.
- Aplicar o uso de banco de dados científicos para tratar, organizar e retirar informações espaciais em grande escala.
- Utilizar algoritmos de associação cruzada multifrequencial para melhorar a correspondência entre objetos identificados.
- Avaliar a redução de diferenças e incertezas posicionais obtidas com a abordagem proposta.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 Associação Cruzada e Desafios

O Cross-Matching (ou associação cruzada) entre catálogos astronômicos é o processo de analisar e identificar a mesma fonte em diferentes levantamentos. Pode haver variação de coordenadas de um mesmo objeto entre os catálogos devido a erros de astrometria, ruídos instrumentais e resoluções distintas. Quando fontes próximas se sobrepõem nos registros, surgem os erros de confusão astrométrica, que trazem dificuldades para especificação precisa do centróide (Hogg, 2001). A associação de fontes distintas gera falsos positivos e a não associação da mesma fonte, falsos negativos, por conta de métodos que utilizam raios de busca fixos, em regiões de baixa densidade.

Budavári e Szalay (2008) sintetizam as limitações da abordagem tradicional e propõem uma mudança de paradigma. A citação longa a seguir, extraída da seção 1 do artigo original, explicita o problema:

> “Hoje, os astrônomos costumam unir dois catálogos definindo um limite para a separação angular das fontes, motivado pelas acurácias astrométricas dos conjuntos de dados envolvidos. [...] O problema com essas formas tradicionais não é que elas se baseiem em suposições e intuições implícitas, mas sim que elas não são simétricas. Embora as correspondências par a par possam ser aceitáveis, não há garantia, nem qualquer medida de qualidade, de que as correspondências finais eleitas sejam plausíveis ou de que a lista esteja completa. Afinal, escolher uma ordem diferente de correspondência par a par produziria um catálogo diferente. Precisamos de algoritmos que sejam simétricos nos catálogos e forneçam uma medida de qualidade confiável que possa ser usada para excluir ou reduzir o peso de combinações improváveis de fontes.” (BUDÁVARI; SZALAY, 2008, p. 302, tradução nossa).

A Tabela 1 contrasta as duas abordagens.

Aspecto	Distância fixa	Abordagem bayesiana (Budavári & Szalay)
Critério de decisão	Separação angular < limiar predefinido	Probabilidade posterior de associação
Uso da densidade local	Ignorado	Explicitamente modelado (prior)
Elipses de erro	Não consideradas (ou apenas o raio)	Incorporadas como distribuições de probabilidade

Simetria entre catálogos	Assimétrica (à depender da ordem)	Simétrica
Desempenho em campos densos	Alto risco de falsos positivos	Robusto, com medida de qualidade
Extensibilidade a múltiplos catálogos	Requer regras ad hoc de encadeamento	Formalismo recursivo e unificado

Fonte: Elaborado pelos autores (2026), com base em Budavári e Szalay (2008) e Hogg (2001).

A Figura 1 ilustra, de forma esquemática, o efeito da confusão astrométrica: em um campo denso, a posição medida de uma fonte fraca pode ser deslocada em relação à sua posição verdadeira, de modo que um raio de busca fixo pode associar a contraparte errada ou não encontrar nenhuma contraparte dentro do limiar.

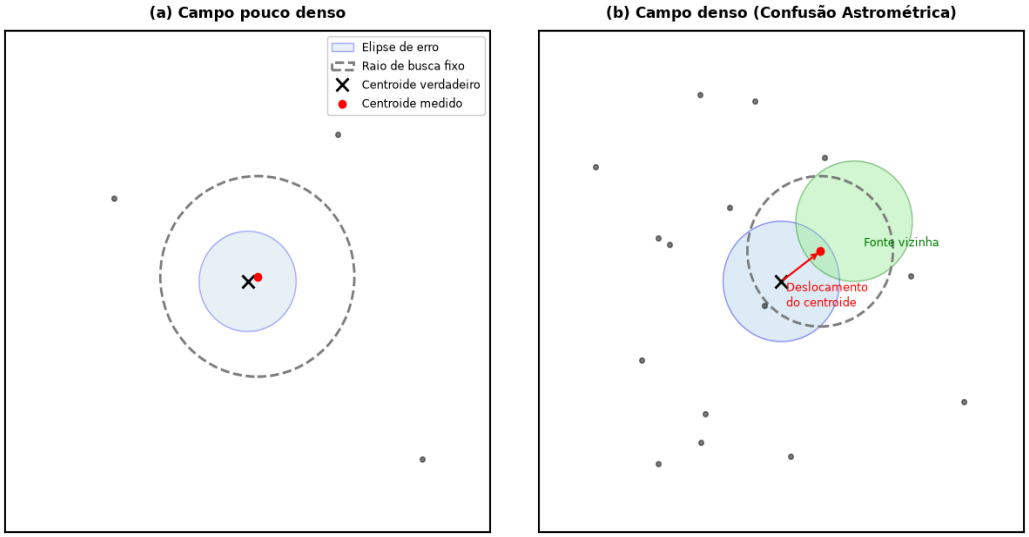


Figura 1 – Efeito esquemático da confusão astrométrica na associação de contrapartes. (a) campo pouco denso, com elipses de erro bem separadas e um raio de busca fixo que associa corretamente; (b) campo denso, com elipses de erro sobrepostas e deslocamento de centróide, mostrando que o raio fixo pode levar a associações incorretas. **Fonte:** adaptado de Hogg (2001).

2.2 O Formalismo Probabilístico de Budavári de Szalay

A partir do teorema de Bayes, o método de Budavári e Szalay (2008) se propõe que, para cada par de fontes, calcula-se a probabilidade de que ambas sejam a mesma entidade física. A incorporação da posição e outras propriedades observacionais como cor, redshift e luminosidade é possível dado ao formalismo simétrico em todos os catálogos.

Para o caso de dois catálogos com erros posicionais gaussianos circulares, o Bayes factor (fator de Bayes) que compara a hipótese de associação (H0) com a hipótese de não associação (H1) é dado pela razão entre as verossimilhança das duas hipóteses. A

probabilidade posterior de associação, P (H0 | d), é obtida multiplicando-se o Bayes factor pelo prior de associação, que depende da densidade local de fontes na região (BUDÁVARI; SZALAY, 2008). Dessa forma, o método penaliza associações em campos densos, onde a probabilidade de uma coincidência fortuita é maior.

Tal convencionalismo é o pilar do algoritmo implementado no Chandra X-ray Center para o cruzamento entre o CSC 2.0 e o SDSS DR15 (ROTS, 2020). O catálogo que se resulta, tem para cada par, uma probabilidade de match e uma separação angular, que foram discretizadas na etapa de exploração e limpeza desta pesquisa.

2.3 Mineração de Regras de Associação e Algoritmo Apriori

A mineração de regras de associação é uma técnica de descoberta de padrões em grandes bases de dados, originalmente aplicada à cesta de compras (HAN; KAMBER; PEI, 2011). O algoritmo de Apriori distingue conjuntos de itens que aparecem com menor frequência, também chamados de itemsets. Com isso, são geradas regras de associação do tipo “se X então Y”, com métricas de suporte, confiança e lift. A frequência do itemset na base é indicada pelo suporte; a probabilidade do consequente dado o antecedente é medida pela confiança; e o lift avalia se a regra ocorre mais do que o esperado.

Três métricas fundamentais avaliam a qualidade de uma regra:

- Suporte: fração das transações que contêm simultaneamente o antecedente e o consequente. Indica a frequência do padrão na base.
- Confiança: probabilidade condicional de o consequente ocorrer dado que o antecedente ocorreu. Mede a força da regra.
- Lift: razão entre a confiança observada e a confiança esperada se antecedente e consequente fossem independentes. Valores de lift maiores que 1 indicam associação positiva.

Freire (2016) aplicou técnicas de mineração e resolução de entidades espaciais em catálogos astronômicos, demonstrando a viabilidade de abordagens computacionais para melhorar a associação. Neste trabalho, o Apriori foi aplicado para descobrir padrões entre as variáveis de qualidade do match (separação, probabilidade, tipo de match) e a classificação morfológica (estrela ou galáxia).

2.4 Aplicação ao Catálogo CSC 2.0 x SDSS DR15

A partir do Chandra X-Ray Center (ROTS,2020) e o algoritmo de Budavári e Szalay (2008) foi gerado o catálogo cruzado utilizado neste projeto. Contendo 35.771 pares, dos quais 60,97% apresentam separação angular inferior a 1” (Figura 2). A distribuição completa, no

entanto, revela uma cauda relevante: 19,52% dos pares têm separação superior a 2", o que evidencia que uma fração não desprezível das associações ocorre em regimes de maior ambiguidade posicional.

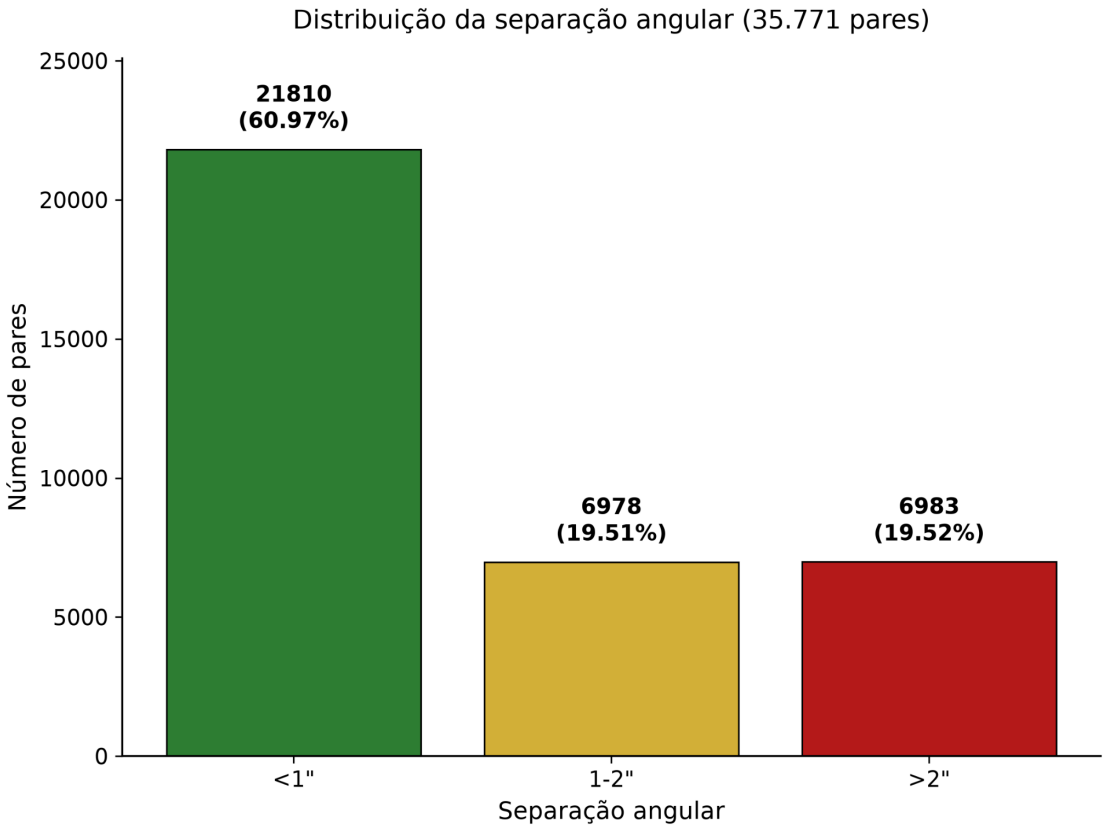


Figura 2 – Distribuição da separação angular dos 35.771 pares do catálogo CSC 2.0 × SDSS DR15. Categorias <1" (21.810 pares; 60,97%), 1-2" (6.978; 19,51%) e >2" (6.983; 19,52%). Fonte: elaborado pelos autores a partir do catálogo cruzado.)

Essa distribuição empírica, combinada com o referencial teórico apresentado, motiva a hipótese central do trabalho: a qualidade do match não é uniforme entre os tipos morfológicos, e a mineração de regras de associação pode revelar padrões sistemáticos que ajudem a refinar a interpretação do catálogo.

3. METODOLOGIA

A pesquisa foi conduzida em cinco etapas, conforme o cronograma do projeto:

- Aquisição e armazenamento: download do catálogo cruzado CSC 2.0 – SDSS DR15 (35.771 pares) e importação para banco de dados PostgreSQL, com criação de índices sobre os identificadores.
- Exploração e limpeza: cálculo de estatísticas descritivas e discretização das variáveis contínuas (separação angular em <1", 1–2" e >2"; probabilidade de

match em alta ≥0,99, média 0,9–0,99 e baixa <0,9). Identificação de inconsistências.

- Mineração de regras de associação: aplicação do algoritmo Apriori (biblioteca mlxtend do Python) sobre a base limpa, com suporte mínimo de 1% e confiança mínima de 60%. Regras ordenadas por lift.
- Validação e interpretação: comparação das regras com a literatura e identificação de padrões astrofísicos.
- Documentação: organização do código e resultados em repositório público e redação do artigo final.

Os resultados das etapas 1 a 4 são apresentados a seguir.

4. RESULTADOS

4.1 Aquisição e Estatísticas Descritivas (Julho)

O catálogo cruzado CSC 2.0 – SDSS DR15 contém 35.771 pares de fontes. A Tabela 2 resume todas as estatísticas descritivas obtidas na etapa de aquisição e exploração inicial.

Tabela 2 – Estatísticas descritivas completas do catálogo cruzado CSC 2.0 × SDSS DR15

Análise	Quantidade	Percentual (%)	Descrição
Total de registros	35.771	100,00	Total de correspondências CSC 2.0 × SDSS DR15
Tipo SDSS: S	18.188	50,85	Objetos classificados como estrela (S)
Tipo SDSS: G	17.583	49,15	Objetos classificados como galáxia (G)
Match probability ≥ 0,9	27.854	77,87	Probabilidade igual ou superior a 90%
Match probability < 0,9	7.917	22,13	Probabilidade inferior a 90%
Match grade: D	32.160	89,91	Registros classificados como D (definitivo)
Match grade: L	3.611	10,09	Registros classificados como L (fraco)

Alta probabilidade + Grade D	27.531	76,96	Probabilidade ≥ 0,9 e Match_grade = D
Alta confiança + Grade D: S	14.408	52,33	Dentro dos 27.531 matches de alta confiança
Alta confiança + Grade D: G	13.123	47,67	Dentro dos 27.531 matches de alta confiança
Match type: E	29.914	83,63	Registros classificados como E (único/estimado)
Match type: R	5.857	16,37	Registros classificados como R (múltiplo/recalculado)
Alta confiança + Grade D: E	25.593	92,26	Dentro dos 27.531 matches de alta confiança
Alta confiança + Grade D: R	1.938	7,04	Dentro dos 27.531 matches de alta confiança

Fonte: Elaborado pelos autores (2026), a partir dos dados do catálogo cruzado.

A Figura 3 cruza separação angular e probabilidade de match. Observa-se a tendência esperada: separações pequenas concentram probabilidades altas, e separações grandes concentram probabilidades baixas. Entretanto, 217 pares (0,61% do total) apresentaram separação <1" combinada a probabilidade baixa (<0,90) — um padrão aparentemente contra intuitivo, explicado pelo fato de o modelo bayesiano ponderar também a densidade local e as elipses de erro.

Figura 3 - Separação angular x probabilidade de match, por categoria.

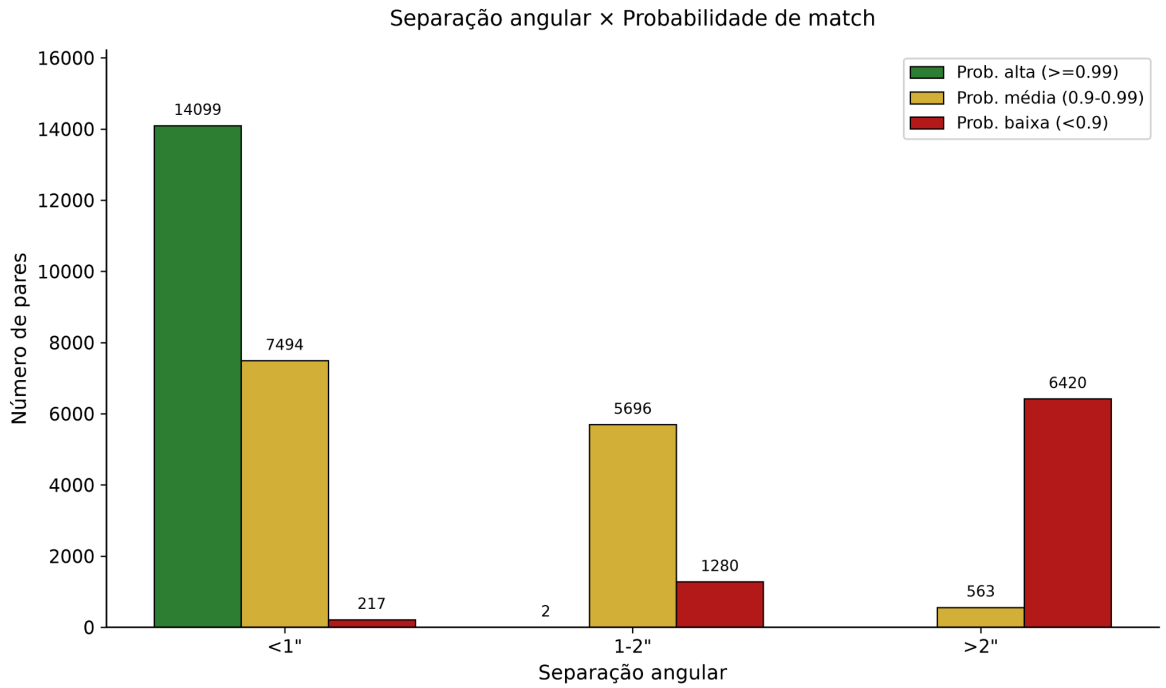


Gráfico de barras agrupadas com os valores: <1" prob alta 14.099, média 7.494, baixa 217; 1-2" prob alta 2, média 5.696, baixa 1.280; >2" prob alta 0, média 563, baixa 6.420. Fonte: elaborado pelos autores.

4.2 Identificação de Inconsistências (Agosto)

Esta etapa foi focada na exploração e limpeza, e teve como principal resultado a probabilidade simultânea de match baixa (<0,90) e separação angular grande (>2') dos 3.385 (10,54%), entre os 32.160 pares classificados como *match_grade* = "D" (match definitivo/confiável). Isto é, resultaram como confiáveis, mas mostram-se contrários aos próprios indicadores estatísticos do cross-matching bayesiano. A figura 4 ilustra tal inconsistência.

Figura 4 - Pares classificados como "D" segundo a consistência entre o rótulo e a evidência estatística.

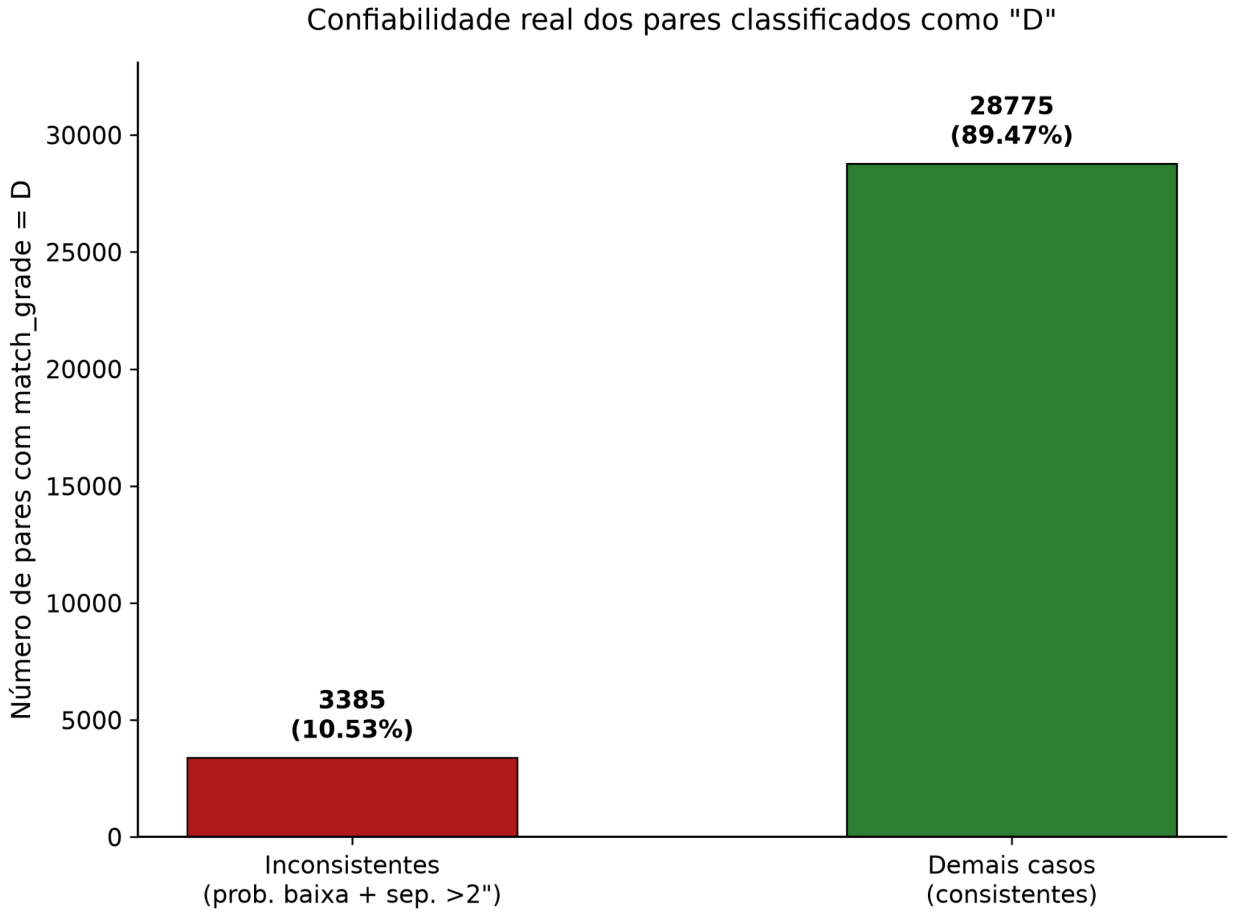


Gráfico de barras: "Inconsistentes (prob. baixa + sep. >2")" = 3.385; "Demais casos (consistentes)" = 28.775. Fonte: elaborado pelos autores.)

Esse padrão é consistente com os erros de confusão astrométrica descritos por Hogg (2001) e com as limitações de métodos de distância fixa em regiões de alta densidade apontadas por Freire, Porto e De Macêdo (2017). Os 3.385 pares inconsistentes foram removidos da base antes da mineração de regras, restando 32.386 pares para a etapa seguinte.

4.3 Mineração de Regras de Associação (Setembro)

A partir do uso e aplicação do algoritmo de Apriori, em base limpa de 32.386 pares, foi utilizado como item as categorias de separação angular, probabilidade de match, tipo SDSS (S/G), *match_type* (E/R) e *match_grade* (D/L). Os parâmetros foram: suporte mínimo de 1% e confiança mínima de 60%. Encontraram-se 213 itemsets frequentes e 449 regras de associação.

A tabela 3 apresenta as regras de maior importância para a astrofísica - os que consequentemente correspondem diretamente à classificação morfológica (estrela ou galáxia).

Tabela 3 - Principais regras de associação com classificação morfológica como consequente

Antecedente	Consequente	Suporte (%)	Confiança (%)	Lift
match_grade=L, match_type=R, separação>2"	tipo = G	5,21	65,42	1,33
match_grade=L, separação>2"	tipo = G	6,00	63,18	1,28
match_type=R, probabilidade=baixa	tipo = G	5,81	68,81	1,29
match_grade=L, probabilidade=baixa	tipo = G	6,34	62,41	1,26

Fonte: elaborado pelos autores.

A regra de maior confiança e lift foi: pares com match_grade=L, match_type=R e separação >2" associam-se à classe morfológica de galáxia (G), com suporte de 5,21%, confiança de 65,4% e lift de 1,33. Esse resultado indica que a combinação de rótulo de *match fraco* (L), tipo de *match múltiplo* (R) e grande separação angular está positivamente associada a objetos classificados como galáxias.

As demais regras (449 no total) incluem muitas relações tautológicas ou circulares, como "probabilidade baixa + separação grande → *match_grade* = L", que refletem a lógica interna do processo de rotulagem do catálogo. No entanto, as 14 regras com classificação morfológica como consequente fornecem insights astrofísicos.

4.4 Interpretação Astrofísica e Validação (Outubro)

O paradigma apontado vai de acordo com a literatura: galáxias são fontes espacialmente extensas, em oposição ao perfil pontual das estrelas. Portanto, se favorecem os deslocamentos posicionais entre catálogos obtidos por diferentes instrumentos devida a maior incerteza na determinação do centróide de emissão (HOGG, 2001). Mostra-se compatível esse comportamento de acordo com as limitações apontadas por Freire, Porto e De Macêdo (2017) para a insuficiência de métodos baseados unicamente em distância fixa em cenários de maior ambiguidade posicional.

A regra encontrada (L + R + sep>2" → G) sugere que, para galáxias, o processo de cross-matching tende a produzir matches mais frouxos (grade L) e com múltiplas possibilidades (type R), exatamente devido à extensão espacial. Isso reforça a hipótese central do projeto: a

associação cruzada por métodos puramente posicionais apresenta limitações sistemáticas relacionadas ao tipo morfológico do objeto, e abordagens probabilísticas são mais adequadas.

Limitações: O catálogo utilizado não contempla informações espectroscópicas ou fotométricas de cor, impossibilitando a identificação direta de subclasses astrofísicas específicas, como núcleos ativos de galáxias (AGN) ou estrelas com atividade cromosférica elevada. A classificação morfológica disponível (estrela/galáxia) é uma aproximação de baixa resolução. Recomenda-se, para trabalhos futuros, o cruzamento complementar com catálogos espectroscópicos (por exemplo, SDSS DR16; AHUMADA et al., 2020).

5. CONCLUSÃO

Esta pesquisa obteve os resultados esperados de acordo com as cinco etapas metodológicas propostas. A obtenção e organização da base de 35.771 pares foi concluída com satisfação. A etapa de exploração e limpeza se fez possível de identificar um paradigma importante de contradição em 10,54% dos registros classificados como match confiável (grade D), que foram retirados para mineração. Utilizar o algoritmo de Apriori sobre a base tratada (32.386 pares) mostrou 449 regras de associação, as quais uma fração relaciona a qualidade do match à classificação morfológica do objeto. A regra principal (L + R + sep>2” -> G, lift 1,33) mostra que galáxias, por serem fontes extensas, tendem a apresentar maior ambiguidade posicional, dando matches mais frouxos.

Os resultados mostram que a hipótese de métodos de distância fixa são limitados e abordagens probabilísticas, combinadas com técnicas de mineração de dados, podem mostrar padrões e incoerências que poderiam não ser vistos. A pergunta de pesquisa foi respondida: é possível aplicar mineração de regras de associação para revelar relações entre variáveis de qualidade do match e propriedades astrofísicas, auxiliando na validação e no refinamento de catálogos cruzados.

Como próximos passos, sugerem-se: (i) incorporar dados espectroscópicos para refinar a classificação morfológica e identificar AGNs; (ii) aplicar a metodologia a outros levantamentos (LSST, Euclid); e (iii) disponibilizar o código e os resultados em repositório público, conforme a etapa 5 da metodologia.

REFERÊNCIAS

AHUMADA, R. et al. The 16th Data Release of the Sloan Digital Sky Surveys: first release from the APOGEE-2 Southern Survey and full release of eBOSS spectra. The Astrophysical Journal Supplement Series, v. 249, n. 1, artigo 3, 2020.

BUDÁVÁRI, Tamás; SZALAY, Alexander S. Probabilistic cross-identification of astronomical sources. The Astrophysical Journal, v. 679, n. 1, p. 301-309, maio 2008. DOI: 10.1086/587156.

CAI, Jianghui et al. Data mining techniques on astronomical spectra data – III. Association analysis. Monthly Notices of the Royal Astronomical Society, v. 532, n. 1, p. 223-240, jul. 2024.

DÍAZ, V. S. P. et al. Enhancing Chandra-Gaia Crossmatching with Machine Learning. Bulletin of the AAS, v. 56, n. 5, 2024. DOI: 10.3847/25c2cfeb.73f78358.

EVANS, I. N. et al. The Chandra Source Catalog. The Astrophysical Journal Supplement Series, v. 189, n. 1, p. 37-82, 2010.

FREIRE, Vinícius Pires de Moura. NACluster: resolvendo entidades em larga escala a partir de múltiplos catálogos de astronomia. 2016. 171 f. Tese (Doutorado em Ciência da Computação) – Centro de Ciências, Universidade Federal do Ceará, Fortaleza, 2016.

FREIRE, Vinícius Pires de Moura; PORTO, Fábio; DE MACÊDO, José A. F. ParallelNACluster: uma estratégia paralela de clusterização para o casamento de múltiplos catálogos. In: SIMPÓSIO BRASILEIRO DE BANCOS DE DADOS (SBBD), 32., 2017, Uberlândia. Anais [...]. Uberlândia: SBC, 2017. p. 32-43.

HAN, Jiawei; KAMBER, Micheline; PEI, Jian. Data Mining: concepts and techniques. 3. ed. Waltham: Morgan Kaufmann, 2011.

HOGG, David W. Confusion errors in astrometry and counterpart association. The Astronomical Journal, v. 121, n. 2, p. 1207-1213, fev. 2001. DOI: 10.1086/318736.

ROTS, A. Xmatch Implementation of the Bayesian Cross-Matching Algorithm. Chandra X-ray Center, 2020. Disponível em: https://cxc.cfa.harvard.edu/cda/files/XmatchQuickSummary.pdf. Acesso em: 21 maio 2026.

SDSS. Sloan Digital Sky Survey – official website. Disponível em: https://www.sdss.org/. Acesso em: 21 maio 2026.

YANG, Haifeng et al. Data mining techniques on astronomical spectra data – II. Classification analysis. Monthly Notices of the Royal Astronomical Society, v. 517, n. 4, p. 5490-5513, dez. 2022.

AGRADECIMENTOS

Agradecemos à Unifacear pela oportunidade e apoio à pesquisa, e à professora Rosanete Grassiani dos Santos pela confiança, orientação e apoio ao nosso estudo e projeto.